

# Atelier 1 : Cluster Spark avec Docker

## Analyse des événements GDELT

Big Data - DIC3 Informatique  
Groupe 2: Awa Diop, Mouhamed Lamine Faye  
Dialika Thiaw et Moussa Ndoye

9 décembre 2025

## Table des matières

<b>1 Introduction - Projet GDELT</b>	<b>3</b>
1.1 Présentation de GDELT . . . . .	3
1.2 Objectif de l'atelier . . . . .	3
1.3 Source des données . . . . .	3
1.4 Fichier utilisé . . . . .	3
1.5 Identification de la colonne pays . . . . .	3
<b>2 Code Source</b>	<b>3</b>
2.1 Architecture du code . . . . .	3
2.1.1 Structure des fichiers . . . . .	4
2.2 Classe GDELTEventCounter . . . . .	4
2.3 Réutilisabilité et flexibilité . . . . .	5
2.4 Module timer.py . . . . .	5
<b>3 Environnement d'exécution local</b>	<b>5</b>
3.1 Configuration Windows . . . . .	5
3.1.1 Prérequis . . . . .	5
3.1.2 Téléchargement de winutils . . . . .	6
3.1.3 Téléchargement de Spark 3.5.7 . . . . .	6
3.2 Vérification de l'installation . . . . .	6
3.3 Exécution locale . . . . .	6
<b>4 Déploiement Docker</b>	<b>7</b>
4.1 Architecture du cluster . . . . .	7
4.2 Fichier docker-compose.yml . . . . .	7
4.3 Démarrage du cluster . . . . .	8
4.4 Interfaces Web . . . . .	9
4.4.1 Spark Master UI (port 8080) . . . . .	9
4.4.2 Spark Worker 1 UI (port 8081) . . . . .	9
4.4.3 Spark Worker 2 UI (port 8082) . . . . .	10
4.5 Exécution sur le cluster . . . . .	10

<b>5 Comparaison des performances</b>	<b>10</b>
5.1 Fichier de test . . . . .	10
5.2 Exécution locale . . . . .	11
5.3 Exécution sur le cluster . . . . .	12
5.4 Tableau comparatif . . . . .	12
<b>6 Conclusion</b>	<b>12</b>
6.1 Points clés . . . . .	13
6.2 Analyse des résultats . . . . .	13
6.3 Perspectives . . . . .	13

# 1 Introduction - Projet GDELT

## 1.1 Présentation de GDELT

Le projet **GDELT** (Global Database of Events, Language, and Tone) est une initiative qui surveille les médias du monde entier en temps réel. Il analyse les actualités diffusées dans plus de 100 langues et identifie les personnes, lieux, organisations, thèmes et événements qui façonnent notre monde.

GDELT est la plus grande base de données ouverte sur le comportement humain à travers le monde, couvrant des événements depuis 1979 jusqu'à aujourd'hui.

## 1.2 Objectif de l'atelier

L'objectif de cet atelier est de **compter le nombre d'événements par pays** à partir des données GDELT, en utilisant Apache Spark pour le traitement distribué.

## 1.3 Source des données

En exploitant le projet GDELT, nous nous sommes rendus sur le site officiel pour récupérer les fichiers de données :

<http://data.gdeltproject.org/events/index.html>

Nous utilisons le format **GDELT 2.0 Events** qui contient 58 colonnes par événement.

## 1.4 Fichier utilisé

Pour l'étude et les tests en local, nous avons téléchargé le fichier :

- **Nom** : 20251208.export.CSV.zip
- **Taille** : 41.4 Mo (compressé)
- **Événements** : 111,373 événements

## 1.5 Identification de la colonne pays

Après analyse du schéma GDELT 2.0, nous avons identifié la **colonne 51** (index à partir de 0) comme étant la colonne **ActionGeo\_CountryCode**. Cette colonne contient les codes pays FIPS à 2 lettres (ex : US, UK, FR, IN).

Ces codes étant uniques par pays, ils sont idéaux pour effectuer le comptage des événements.

# 2 Code Source

## 2.1 Architecture du code

Le code est organisé de manière orientée objet avec une classe principale **GDELTEventCounter** qui encapsule toute la logique de traitement Spark.

### 2.1.1 Structure des fichiers

```
app/
    __init__.py           # Initialisation du package
    event_counter.py     # Classe principale
    timer.py              # Module de mesure du temps
```

## 2.2 Classe GDELTEventCounter

```
1 class GDELTEventCounter:
2     """Classe pour compter les evenements GDELT par pays."""
3
4     def __init__(self, master: str = "local[*]",
5                  app_name: str = "GDELTEventCounter",
6                  country_col: int = 51,
7                  has_header: bool = False):
8         self.spark = SparkSession.builder \
9             .appName(app_name) \
10            .master(master) \
11            .getOrCreate()
12         self.country_col = country_col
13         self.has_header = has_header
14         self.df = None
15         self.results = None
16
17     @timed
18     def load_data(self, input_path: str) -> DataFrame:
19         """Charge les donnees GDELT depuis un fichier CSV."""
20         self.df = self.spark.read.csv(
21             input_path, sep='\t',
22             header=self.has_header, inferSchema=True
23         )
24         return self.df
25
26     @timed
27     def count_by_country(self) -> DataFrame:
28         """Compte les evenements par pays."""
29         col_name = self.df.columns[self.country_col] \
30             if self.has_header else f"_c{self.country_col}"
31         country_df = self.df.withColumnRenamed(col_name,
32                                              "CountryCode")
33         self.results = country_df.filter(
34             col("CountryCode").isNotNull()
35         ).groupBy("CountryCode") \
36             .agg(count("*").alias("EventCount")) \
37             .orderBy(col("EventCount").desc())
38         return self.results
39
40     @timed
41     def save_results(self, output_path: str) -> None:
```

```

41     """ Sauvegarde les résultats en CSV """
42     self.results.coalesce(1).write \
43         .mode("overwrite").option("header", "true") \
44         .csv(output_path)

```

## 2.3 Réutilisabilité et flexibilité

Le code est conçu pour être **réutilisable** et **flexible** grâce aux paramètres de ligne de commande :

Argument	Description	Défaut
-input	Chemin du fichier GDELT	datas/20251208.export.CSV
-output	Chemin de sortie CSV	output/event_counts
-master	URL du Spark Master	local[*]
-country-col	Index de la colonne pays	51
-header	Fichier avec en-tête	False

TABLE 1 – Arguments de ligne de commande

## 2.4 Module timer.py

Le décorateur `@timed` permet de mesurer automatiquement le temps d'exécution de chaque méthode :

```

1 def timed(func):
2     """Decorateur pour mesurer le temps d'execution."""
3     @wraps(func)
4     def wrapper(*args, **kwargs):
5         start = time.time()
6         result = func(*args, **kwargs)
7         end = time.time()
8         print(f"[TIMER] {func.__name__}: {end - start:.2f} "
9               "secondes")
10        return result
11    return wrapper

```

# 3 Environnement d'exécution local

## 3.1 Configuration Windows

L'environnement local est configuré sur Windows avec les composants suivants :

### 3.1.1 Prérequis

- **Java** : JDK 11 ou 17
- **Apache Spark** : Version 3.5.7
- **Hadoop** : Binaires Windows (winutils)

### 3.1.2 Téléchargement de winutils

Pour que Spark puisse écrire des fichiers sur Windows, nous avons téléchargé les binaires Hadoop depuis :

<https://github.com/cdarlint/winutils/tree/master/hadoop-3.3.6/bin>

Les fichiers ont été placés dans C:\hadoop\bin\.

### 3.1.3 Téléchargement de Spark 3.5.7

Apache Spark a été téléchargé depuis :

<https://www.apache.org/dyn/closer.lua/spark/spark-3.5.7/spark-3.5.7-bin-hadoop3.tgz>

### 3.2 Vérification de l'installation


```
spark-submit --version
```

FIGURE 1 – Vérification de la version de Spark

### 3.3 Exécution locale

Pour lancer le programme en local :

```
spark-submit app/event_counter.py --input datas/20251208.export.CSV
```



The screenshot shows two adjacent Windows PowerShell windows. Both windows have the title 'Windows PowerShell' and are running the same command: `spark-submit .\app\event_counter.py`. The output of the command is displayed in both windows, showing the configuration of the SparkContext, the version of Spark (3.5.7), and various log messages from the application's execution.

```
PS C:\Users\Lamine-f\Workspace\BIG DATA\Atelier 1> spark-submit .\app\event_counter.py
Configuration:
- Master: local[*]
- Input: datas/20251208.export.CSV
- Output: output/event_counts_by_country
25/12/09 18:39:36 INFO SparkContext: Running Spark version 3.5.7
25/12/09 18:39:36 INFO SparkContext: OS info Windows 11, 10.0, amd64
25/12/09 18:39:36 INFO SparkContext: Java version 21.0.8
25/12/09 18:39:36 INFO ResourceUtils: =====
25/12/09 18:39:36 INFO ResourceUtils: No custom resources configured for spark.driver.
25/12/09 18:39:36 INFO ResourceUtils: =====
25/12/09 18:39:36 INFO SparkContext: Submitted application: GDELTEventCounter
25/12/09 18:39:36 INFO ResourceProfile: Default ResourceProfile created, executor resources: Map(cores -> name: cores, amount: 1, script: , vendor: , memory -> name: memory, amount: 1024, script: , vendor: , offHeap -> name: offHeap, amount: 0, script: , vendor: ), task resources: Map(cpus -> name: cpus, amount: 1.0)
25/12/09 18:39:36 INFO ResourceProfile: Limiting resource is cpu
25/12/09 18:39:36 INFO ResourceProfileManager: Added ResourceProfile id: 0
25/12/09 18:39:36 INFO SecurityManager: Changing view acls to: Lamine-f
25/12/09 18:39:36 INFO SecurityManager: Changing modify acls to: Lamine-f
25/12/09 18:39:36 INFO SecurityManager: Changing view acls groups to:
25/12/09 18:39:36 INFO SecurityManager: SecurityManager: authentication disabled; ui acls disabled; users with view permissions: Lamine-f; groups with view permissions: EMPTY; users with modify permissions: Lamine-f; groups with modify permissions: EMPTY
25/12/09 18:39:36 INFO Utils: Successfully started service 'sparkDriver' on port 62021.
25/12/09 18:39:37 INFO SparkEnv: Registering MapOutputTracker
25/12/09 18:39:37 INFO SparkEnv: Registering BlockManagerMaster
25/12/09 18:39:37 INFO BlockManagerMasterEndpoint: Using org.apache.spark.storage.DefaultTopologyMapper for getting topology information
25/12/09 18:39:37 INFO BlockManagerMasterEndpoint: BlockManagerMasterEndpoint up
```

FIGURE 2 – Exécution locale sur le fichier 20251208.export.CSV

CountryCode	EventCount
US	30787
UK	6115
IN	6025
IS	4008
NI	3682
AS	3292
CH	3006
UP	2932
RS	2884
CA	2545
PK	1672
SY	1557
FR	1513
TH	1391
GM	1339
SF	1330
JA	1261
CB	1229
EI	1211
GH	951
QA	848
RP	838
IR	826
ID	805
IT	720
TU	710
NZ	677
BG	660
VE	641
KS	573

only showing top 30 rows

FIGURE 3 – Résultats de l'exécution locale

## 4 Déploiement Docker

### 4.1 Architecture du cluster

Le cluster Spark est déployé avec Docker Compose et comprend :

- **1 Spark Master** : Coordonne les tâches
- **2 Spark Workers** : Exécutent les tâches

Chaque worker est configuré avec :

- 2 Go de mémoire
- 2 cœurs CPU

### 4.2 Fichier docker-compose.yml

```

1 services:
2   spark-master:
3     image: apache/spark:3.5.0

```

```

4   container_name: spark-master
5   ports:
6     - "8080:8080" # Web UI Master
7     - "7077:7077" # Port Spark Master
8     - "4040:4040" # Application UI
9   volumes:
10    - ./datas:/data
11    - ./app:/app
12    - ./output:/output
13
14 spark-worker-1:
15   image: apache/spark:3.5.0
16   container_name: spark-worker-1
17   environment:
18     - SPARK_WORKER_MEMORY=2G
19     - SPARK_WORKER_CORES=2
20   ports:
21     - "8081:8081"
22
23 spark-worker-2:
24   image: apache/spark:3.5.0
25   container_name: spark-worker-2
26   environment:
27     - SPARK_WORKER_MEMORY=2G
28     - SPARK_WORKER_CORES=2
29   ports:
30     - "8082:8081"
31
32 networks:
33   spark-net:
34     driver: bridge

```

### 4.3 Démarrage du cluster

```

# Demarrer le cluster
docker-compose up -d

# Vérifier les conteneurs
docker ps

```




FIGURE 4 – Docker Desktop - Conteneurs du cluster Spark

## 4.4 Interfaces Web

### 4.4.1 Spark Master UI (port 8080)

Spark Master at [spark://172.23.0.2:7077](http://spark://172.23.0.2:7077)

URL: [spark://172.23.0.2:7077](http://spark://172.23.0.2:7077)  
Alive Workers: 2  
Cores in use: 4 Total, 0 Used  
Memory in use: 4.0 GiB Total, 0.0 B Used  
Resources in use:  
Applications: 0 Running, 0 Completed  
Drivers: 0 Running, 0 Completed  
Status: ALIVE

Workers (2)					
Worker Id	Address	State	Cores	Memory	Resources
worker-20251209183018-172.23.0.3-36149	172.23.0.3:36149	ALIVE	2 (0 Used)	2.0 GiB (0.0 B Used)	
worker-20251209183018-172.23.0.4-45355	172.23.0.4:45355	ALIVE	2 (0 Used)	2.0 GiB (0.0 B Used)	

Running Applications (0)								
Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration

Completed Applications (0)								
Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration

FIGURE 5 – Interface Web du Spark Master

#### 4.4.2 Spark Worker 1 UI (port 8081)

The screenshot shows a web browser window with the URL `localhost:8081`. The title bar says "Spark 3.5.0" and "Spark Worker at 172.23.0.3:36149". Below this, there is a summary of worker resources:

- ID: worker-20251209183018-172.23.0.3-36149
- Master URL: `spark://172.23.0.2:7077`
- Cores: 2 (0 Used)
- Memory: 2.0 GiB (0.0 B Used)
- Resources:

A "Back to Master" link is present. Below this, a section titled "Running Executors (0)" is shown with a table header:

ExecutorID	State	Cores	Memory	Resources	Job Details	Logs
------------	-------	-------	--------	-----------	-------------	------

FIGURE 6 – Interface Web du Worker 1

#### 4.4.3 Spark Worker 2 UI (port 8082)

The screenshot shows a web browser window with the URL `localhost:8082`. The title bar says "Spark 3.5.0" and "Spark Worker at 172.23.0.4:45355". Below this, there is a summary of worker resources:

- ID: worker-20251209183018-172.23.0.4-45355
- Master URL: `spark://172.23.0.2:7077`
- Cores: 2 (0 Used)
- Memory: 2.0 GiB (0.0 B Used)
- Resources:

A "Back to Master" link is present. Below this, a section titled "Running Executors (0)" is shown with a table header:

ExecutorID	State	Cores	Memory	Resources	Job Details	Logs
------------	-------	-------	--------	-----------	-------------	------

FIGURE 7 – Interface Web du Worker 2

### 4.5 Exécution sur le cluster

```
docker exec spark-master /opt/spark/bin/spark-submit \
--master spark://spark-master:7077 \
/app/event_counter.py \
--input /data/20251208.export.CSV \
--output /output/results
```

## 5 Comparaison des performances


Avec un cluster de 3 noeuds (1 master + 2 workers), nous avons testé les performances avec un fichier volumineux.

### 5.1 Fichier de test

— Fichier : GDELT.MASTERREDUCEDV2.1979-2013.zip


- Taille : 6.12 Go (compressé)
- Événements : 87,298,047 événements
- Période : 1979 à 2013

## 5.2 Exécution locale




```
PS C:\Users\Lamine-f\Workspace\BIG DATA\Atelier 1> spark-submit .\app\event_counter.py --input .\datas\GDELT.MASTERREDUCEDV2.TXT --header --country-col 1 --output .\output\results_reduced
Configuration:
  - Master: local[*]
  - Input: .\datas\GDELT.MASTERREDUCEDV2.TXT
  - Output: .\output\results_reduced
  - Country Col: 1
  - Header: True
25/12/09 19:08:23 INFO SparkContext: Running Spark version 3.5.7
25/12/09 19:08:23 INFO SparkContext: OS info Windows 11, 10.0, amd64
25/12/09 19:08:23 INFO SparkContext: Java version 21.0.8
25/12/09 19:08:23 INFO ResourceUtils: =====
25/12/09 19:08:23 INFO ResourceUtils: No custom resources configured for spark.driver.
25/12/09 19:08:23 INFO ResourceUtils: =====
25/12/09 19:08:23 INFO SparkContext: Submitted application: GDELTEventCounter
25/12/09 19:08:23 INFO ResourceProfile: Default ResourceProfile created, executor resources: Map(cores -> name: cores, amount: 1, script: , vendor: , memory -> name: memory, amount: 1024, script: , vendor: , offHeap -> name: offHeap, amount: 0, script: , vendor: ), task resources: Map(cpu -> name: cpus, amount: 1.0)
25/12/09 19:08:23 INFO ResourceProfile: Limiting resource is cpu
25/12/09 19:08:23 INFO ResourceProfileManager: Added ResourceProfile id: 0
25/12/09 19:08:23 INFO SecurityManager: Changing view acls to: Lamine-f
25/12/09 19:08:23 INFO SecurityManager: Changing modify acls to: Lamine-f
25/12/09 19:08:23 INFO SecurityManager: Changing view acls groups to:
25/12/09 19:08:23 INFO SecurityManager: Changing modify acls groups to:
25/12/09 19:08:23 INFO SecurityManager: SecurityManager: authentication disabled; ui acls disabled; users with view permissions: Lamine-f; groups with view permissions: EMPTY; users with modify permissions: Lamine-f; groups with modify permissions: EMPTY
25/12/09 19:08:23 INFO Utils: Successfully started service 'sparkDriver' on port 53462.
25/12/09 19:08:23 INFO SparkEnv: Registering MapOutputTracker
25/12/09 19:08:23 INFO SparkEnv: Registering BlockManagerMaster
```

FIGURE 8 – Lancement du script en local - Gros fichier



```
Nombre total d'événements chargés: 87298046
[TIMER] load_data: 63.75 secondes
[TIMER] count_by_country: 0.13 secondes
```

FIGURE 9 – Temps de chargement et comptage - Local



```
[TIMER] save_results: 27.38 secondes
=====
[TIMER] run: 118.55 secondes
```

FIGURE 10 – Temps de sauvegarde et total - Local

### 5.3 Exécution sur le cluster

```

PS C:\Users\Lamine-f\Workspace\BIG DATA\Atelier 1> docker exec spark-master /opt/spark/bin/spark-submit --master spark://spark-master:7077 /app/event_counter.py --input /data/GDELT.MASTERREDUCEDV2.TXT --header --country-col 1 --output /out | put/results_reduced
Configuration:
  - Master: local[*]
  - Input: /data/GDELT.MASTERREDUCEDV2.TXT
  - Output: /output/results_reduced
  - Country Col: 1
  - Header: True
25/12/09 19:00:12 INFO SparkContext: Running Spark version 3.5.0
25/12/09 19:00:12 INFO SparkContext: OS info Linux, 6.6.87.2-microsoft-standard-WSL2, amd64
25/12/09 19:00:12 INFO SparkContext: Java version 11.0.20.1
25/12/09 19:00:12 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
25/12/09 19:00:12 INFO ResourceUtils: =====
25/12/09 19:00:12 INFO ResourceUtils: No custom resources configured for spark.driver.
25/12/09 19:00:12 INFO ResourceUtils: =====
25/12/09 19:00:12 INFO SparkContext: Submitted application: GDELTEventCounter
25/12/09 19:00:12 INFO ResourceProfile: Default ResourceProfile created, executor resources: Map(cores -> name: cores, amount: 1, script: , vendor: , memory -> name: memory, amount: 1024, script: , vendor: , offHeap -> name: offHeap, amount: 0, script: , vendor: ), task resources: Map(cpus -> name: cpus, amount: 1.0)
25/12/09 19:00:12 INFO ResourceProfile: Limiting resource is cpu
25/12/09 19:00:12 INFO ResourceProfileManager: Added ResourceProfile id: 0
25/12/09 19:00:12 INFO SecurityManager: Changing view acls to: spark
25/12/09 19:00:12 INFO SecurityManager: Changing modify acls to: spark
25/12/09 19:00:12 INFO SecurityManager: Changing view acls groups to:
25/12/09 19:00:12 INFO SecurityManager: Changing modify acls groups to:
25/12/09 19:00:12 INFO SecurityManager: SecurityManager: authentication disabled; ui acls disabled; users with view permissions: spark; groups with view permissions: EMPTY; users with modify permissions: spark; groups with modify permissions: spark; users with total permissions: spark; groups with total permissions: EMPTY

```

FIGURE 11 – Lancement du script sur le cluster - Gros fichier

```

Nombre total d'événements chargés: 87298046
[TIMER] load_data: 102.12 secondes
[TIMER] count_by_country: 0.12 secondes

```

FIGURE 12 – Temps de chargement et comptage - Cluster

```

[TIMER] save_results: 43.12 secondes
=====
[TIMER] run: 184.44 secondes

```

FIGURE 13 – Temps de sauvegarde et total - Cluster

### 5.4 Tableau comparatif

Métrique	Local	Cluster (3 nœuds)
Chargement des données	63.75 s	102.12 s
Comptage par pays	0.13 s	0.12 s
Sauvegarde des résultats	27.38 s	43.12 s
<b>Temps total</b>	<b>118.55 s</b>	<b>184.44 s</b>

TABLE 2 – Comparaison des temps d'exécution - Fichier GDELT Reduced (87M événements)

## 6 Conclusion

Cet atelier a permis de mettre en place une infrastructure de traitement distribué avec Apache Spark pour analyser les données GDELT.

## 6.1 Points clés

- **Flexibilité du code** : Le programme est paramétrable et réutilisable pour différents formats de fichiers GDELT.
- **Scalabilité** : Le déploiement Docker permet d'ajouter facilement des workers pour augmenter la capacité de traitement.
- **Mesure des performances** : Le module timer permet de comparer objectivement les temps d'exécution.

## 6.2 Analyse des résultats

Les résultats montrent que l'exécution locale est plus rapide pour ce jeu de données (118.55 s vs 184.44 s). Cela s'explique par :

- **Overhead de distribution** : La sérialisation et le transfert des données entre le master et les workers ajoutent un délai significatif.
- **Taille du fichier** : Avec 87 millions d'événements ( 2.5 Go), le fichier n'est pas assez volumineux pour amortir le coût de la distribution.
- **Environnement Docker** : L'exécution dans des conteneurs sur une même machine ajoute une couche de virtualisation.

Le cluster distribué devient avantageux lorsque :

- Le volume de données dépasse plusieurs dizaines de Go
- Les workers sont sur des machines physiques distinctes
- Le traitement est plus complexe (jointures, agrégations multiples)

## 6.3 Perspectives

Ce travail pourrait être étendu pour :

- Analyser d'autres dimensions des données GDELT (acteurs, types d'événements)
- Déployer sur un cluster cloud (AWS EMR, Google Dataproc)
- Implémenter un traitement en temps réel avec Spark Streaming